MASTER MIAGE 2ème année
Université Paris Nanterre

Mémoire de fin d'études

Étude des méthodes de classification pour la désignation de parcours universitaire

Auteur :
Nathan Michanol

Tuteur :
Pr. Marta Rukoz

Mars 2019 — Juin 2019

Remerciements

Je tiens à remercier ma tutrice, madame Marta Rukoz pour son suivi durant la rédaction de ce mémoire. Les conseils, l'aide et le cadre qu'elle a pu m'apporter durant la rédaction de ce dernier m'ont vraiment été très utiles.

Table des matières

Table des figures

Introduction

Afin d'orienter les étudiants arrivants en première année de licence vers un parcours qui leur semble le plus adapté, il serait intéressant de pouvoir leur fournir un aperçu des chemins suivis par leur prédécesseur.
À cet effet, notre solution devra pouvoir répondre aux problématiques suivantes :

- Comment catégoriser les différentes filières universitaires ?
- Quel secteur l'étudiant sera-t-il susceptible de pouvoir intégrer ?
- Fournir une modélisation de la trajectoire représentée par les différents parcours.

Pour se faire, la solution proposée devra être en mesure de traiter une base de données constituée de documents. Afin de tenter d'apporter une réponse aux deux premières problématiques. La première partie de ce mémoire se concentrera sur l'étude des différentes méthodes de clustering existantes afin de potentiellement apporter un premier élément de réponse concernant cette problématique de catégorisation des données. De plus, pour cette première étape de catégorisation nous nous baserons sur les informations suivantes :

- Un mot clé représentant une filière
- L'ordre dans lequel ceux-ci sont rencontrés

Dans la suite de ce document seront étudiés les différents types de clusters existants ainsi que les différents algorithmes. Dans un second temps, nous étudierons les types de clusters existants ainsi que les différentes méthodes de clustering et algorithmes. En outre, le choix de l'algorithme se fera en fonctions des critères suivants :

- Capacité à traiter un jeu de données numérique.
- La difficulté d'implémentation.
- La sensibilité au bruit.
- La scalabilité.

Enfin, nous terminerons ce document par un chapitre de conclusion.

Chapitre 1

État de l'art du clustering

Le terme clustering fait référence au concept de classification non supervisée. Ce concept fait lui-même partie d'une plus grande famille qu'est l'apprentissage non supervisé. À l'inverse de l'apprentissage supervisé qui nécessite des données déjà segmentées, le clustering vise quant à lui à déterminer une segmentation du jeu de données étudié. Dans ce cas, l'intervention humaine n'est pas nécessaire étant donné que l'ordinateur détermine les différentes segmentations sans l'apport de variables cibles fournies à l'algorithme. L'analyse de cluster permet donc d'identifier des groupes de données relativement homogènes sur la base de leur similitude basée sur des caractéristiques données. Dans notre cas, cela peut par exemple être le type d'emploi occupé en fonction des filières suivies par d'anciens étudiants. Cependant, analyser différents profils d'individus peut représenter des difficultés techniques importantes, c'est pourquoi cette première section du document présentera les différentes solutions possibles pouvant apporter une réponse à cette difficulté de classification des parcours.

1.1 La préparation des données

Lorsqu'une segmentation basée sur des clusters est utilisée, il existe plusieurs formes de préparations de données pouvant aider à la formation des différents segments.

1.1.1 La transformation des variables

Il existe deux types de transformation :
- La modification de la portée des variables connues
- La modification de la forme de distribution

L'utilisation de la standardisation est motivée par le fait que l'analyse de cluster implique une étude implicite du poids des objets afin de pouvoir se concentrer sur ceux possédant une variance plus élevée. Les méthodes de standardisation les plus communes sont les suivantes [1] :
- Multiplication de chaque variable par une différente constante.
- Utilisation des techniques de réduction de dimensions, qui est un processus visant à réduire le nombre de variables aléatoires afin d'obtenir un jeu de

variables principal.
— Multiplier chaque variable par une différente constante afin que chacune d'entre elles ait une portée commune.

La modification de la distribution quant à elle est motivée par les mêmes problématiques que dans d'autres secteurs ayant recours aux statistiques, qui sont d'extrêmes variations par rapport à ce qui est considéré «normal» dans le cas étudié. Celles-ci entrainent des analyses pouvant induire en erreur. Par conséquent lorsque le poids des variables est modifié le but est d'identifier et supprimer leur longue traine qui correspond à un nombre de variables possédant des valeurs très supérieures ou inférieures à la moyenne.

1.1.2 La détection d'outliers

Dans des secteurs comme le Data-Mining, un outlier ou données aberrantes est une observation se distinguant des autres par le fait qu'il représente une valeur extrême. À noter que cette observation peut être soit anormalement élevée ou basse selon le cas étudié. Par conséquent, une interprétation d'un jeu de données contenant un nombre important d'outliers peut amener à l'erreur. Ceci implique que la décision de considérer ou non les outliers doit être prise au moment de la construction du modèle de données. Il est à remarquer qu'en fonction du cas étudié, il n'existe pas de définition mathématique déterminant ce qui constitue un outlier. Toutefois, les causes retenues pouvant expliquer leur présence sont :

— L'erreur humaine
— Une erreur lors de la transmission/transcription des données
— Un changement de procédure

Des méthodes existent cependant afin d'aider à la détection telles que la droite de Henry ou encore la technique des boites à moustaches.

La droite de Henry

La droite de Henry est méthode graphique permettant d'évaluer «la normalité» d'une distribution pour une série d'observations. Cela permet à la lecture du graphique obtenu de repérer rapidement la moyenne et l'écart type du jeu de données traité.(figure 1.1)

Les points indiquent toutes les valeurs des fréquences réelles pour les différentes valeurs attribuées à une variable. Si la distribution est considérée comme «normale» alors tous les points devraient se trouver sur la droite.

la technique des boites à moustaches

Une boite à moustaches ou box-plot est, en statistiques, une représentation graphique permettant pour un jeu de données de représenter la médiane, les quartiles et les centiles. Cette méthode est principalement utilisée afin de comparer un même caractère dans deux populations de tailles différentes.

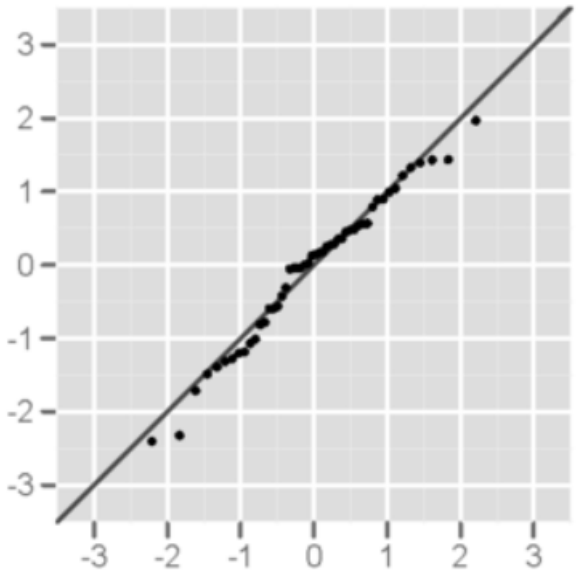

FIGURE 1.1 – Représentation d'une droite de Henry

1.2 La mesure de distance

Le choix d'une méthode de mesure de distance est une étape critique pour les méthodes de clustering, son choix ayant une très forte influence sur le résultat final. En effet, la méthodologie choisie définira comment les ressemblances entre deux éléments sont calculées et influera par conséquent sur la forme des clusters également. Les deux méthodes les plus communes de mesure sont la distance euclidienne illustrée par la formule suivante (figure1.2) :

$$d_{euc}(x,y) = \sqrt{\sum_{i=1}^{n}(x_i - y_i)^2}$$

FIGURE 1.2 – Distance euclidienne

Dans cette méthode, la distance est calculée en effectuant le carré de l'ensemble des distances mises au carré pour toutes les variables satisfaisant un critère donné. La seconde méthode communément utilisée est la distance de Manhattan, appelée également «taxi-distance». Celle-ci, pour un point A et B de coordonnées respectives (X_a,Y_a) et (X_b,Y_b) est définie de la façon suivante :

$$d(A,B) = [X_b - X_a] + [Y_b - Y_a]$$

FIGURE 1.3 – Distance de Manhattan

À l'inverse de la méthode euclidienne qui pourrait être influencée par des valeurs inhabituelles, le calcul de la distance de Manhattan va s'effectuer selon la différence moyenne entre les dimensions. La présence de valeurs aberrantes impactera le résultat de façon réduite étant donné qu'elles ne seront pas élevées au carré contrairement à la méthode euclidienne. Cette méthode aura donc tendance à donner le même type de résultat.

1.3 Les types de clusters

La finalité du clustering étant de trouver des groupes d'objets présentant des similarités définies en fonction du but recherché. Il existe toutefois une multitude de types de cluster qui seront étudiés au sein de cette section. Chacun sera présenté avec ses avantages et inconvénients en fonction de notre cas avant de statuer sur le type qui sera utilisé pour le reste de ce document.

1.3.1 Well-Separated

Un cluster «well-separated» est un regroupement de points de telle façon à ce que tous les points faisant partie d'un même cluster présentent de fortes ressemblances entre eux comparées aux points d'un cluster extérieur(figure 1.6). Si la population du cluster est suffisamment bien compartimentée, ce type de cluster permet de faire fonctionner n'importe quelle méthode de clustering de façon efficace.

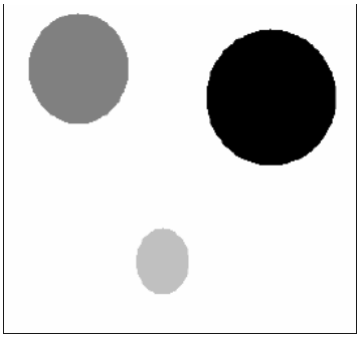

FIGURE 1.4 – Well separated clusters

1.3.2 Graph-Based

Le graph-based cluster est utilisé dans les cas ou les données peuvent être représenté sous forme de graphe dont les nœuds sont des objets et les liens représentent les connexions entre ceux-ci. Dans cette situation, un cluster peut être défini comme un composant connecté. C'est-à-dire un groupe d'objets liés les uns aux autres au sein du même groupe. Ce type de classification permet de visualiser facilement d'importants jeux de données. La théorie des graphes peut être utilisée afin d'apporter des informations plus précises sur le jeu de données en ce qui concerne les clusters, cliques et outliers. Une approche hiérarchique peut être employée à travers la création d'un arbre couvrant de poids minimal ou minimum spanning tree. Dans un contexte où un graph G est connexe, l'arbre est un sous-graphe connexe avec un poids minimal contenant tous les nœuds du graphe d'origine G et ne possédant pas de cycle. Il existe deux algorithmes permettant d'établir ce type d'arbre, l'algorithme de Prim et l'algorithme de Kruskal.

L'algorithme de Prim

L'algorithme de Prim est un algorithme dit « glouton », c'est-à-dire qu'il va pour chaque étape effectuer un choix local jugé optimum. Cet algorithme (figure ...) va s'exécuter en choisissant un axe de poids minimal jusqu'à ce que tous les sommets aient été atteints. Il existe cependant une part d'indéterminisme, il est en effet possible que deux exécutions de cet algorithme renvoient chacun une solution différente. À noter que celle-ci sera tout de même optimale.

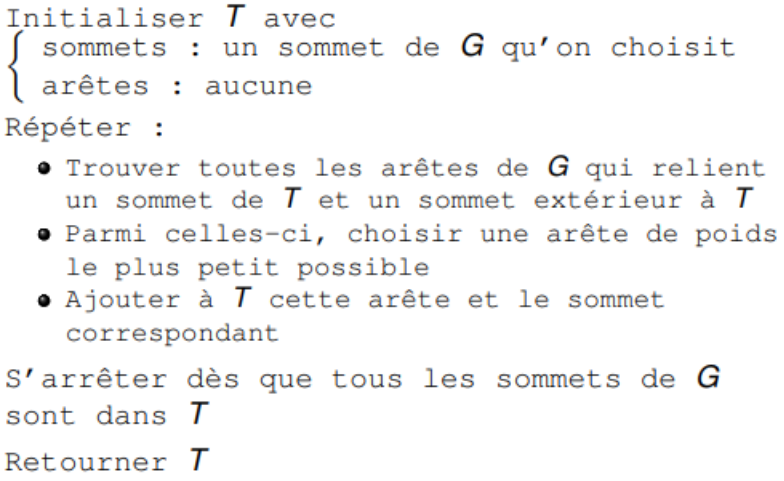

FIGURE 1.5 – Algorithme de Prim

1.3.3 Density-Based

A travers l'utilisation d'un density-based cluster, le but est de détecter les zones ou les points formant des clusters sont concentrés et celles ou les points sont séparés par des zones vides ou par des zones contenant très peu de points (figure 1.4). Les points ne faisant pas partie d'un agrégat sont ici considérés comme du bruit. Ce type de définition est utilisée lorsque les clusters s'entrecroisent ou sont irréguliers.[12] Il est également possible d'avoir recours à ce type de classification lorsque du bruit est présent, celui-ci peut former des ponts entre les clusters lorsqu'un autre type de classification est utilisée.

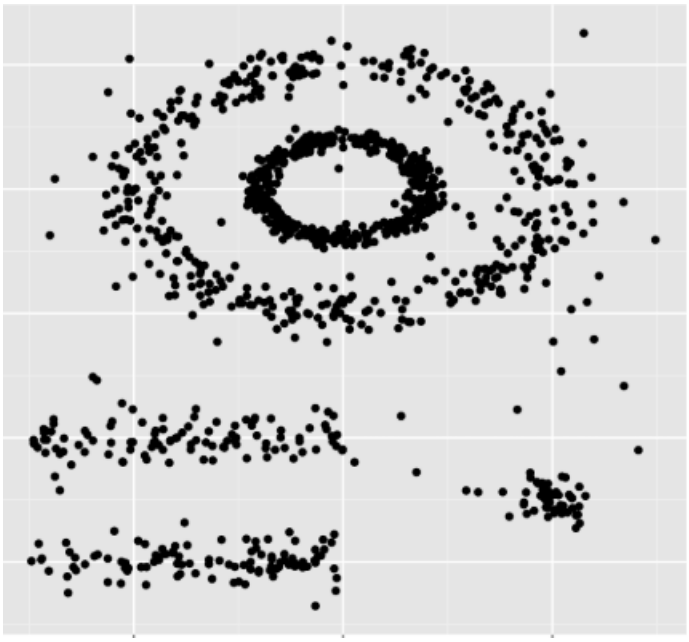

FIGURE 1.6 – Density based clusters

1.4 Les méthodes et algorithmes

Dans cette section seront décrits les principaux algorithmes utilisés lorsque des techniques de clustering sont employées. Les avantages et inconvénients de chacun seront présentés en fonction du cas présenté dans l'introduction.

1.4.1 Le clustering hiérarchique

Parmi les différents types de clustering existants [12], le premier étudié sera le clustering hiérarchique. Très utilisé comme outil d'analyse de données, l'idée principale de cette méthode est de construire un arbre binaire fusionnant de façon successive les groupes de points similaires. L'un des avantages de cette façon de procéder est tout d'abord l'apport de l'arbre qui permet d'avoir une vision globale des données traitées. De plus, cette méthodologie possède ses propres outils de visualisation qui sont le dendrogramme et la classification double. Le dendrogramme permet d'illustrer l'arrangement des clusters (figure 1.3)[2] :

- la racine de l'arbre est formée par un cluster contenant l'ensemble des objets.
- chaque nœud de l'arbre constitue un cluster.
- l'union des objets contenus par les nœuds fils correspond aux objets présents dans le nœud racine.
- les paliers sont indexés en fonction de l'ordre de construction.

Tandis que la classification double est une technique d'exploration de données non supervisées permettant de segmenter concurremment les lignes et les colonnes d'une matrice. L'autre avantage du clustering hiérarchique est sa facilité d'implémentation dans des algorithmes tels que K-Means en plus de fournir une représentation graphique comme dit précédemment. Afin d'établir un arbre hiérarchique, le processus de clustering a recours à deux méthodes qui sont la méthode agglomérative et la méthode divisive.
Un regroupement agglomératif traite chaque objet comme un seul élément qui à chaque étape de l'algorithme est fusionné avec un second objet présentant le plus de similarités en un nouveau cluster de plus grande taille. Ce processus est répété jusqu'à que ce que tous les points soient membre d'un seul et même cluster. À l'inverse d'un regroupement agglomératif qui utilise une approche «bottom-up», les algorithmes divisifs utilisent une approche «top-down». Ces algorithmes débutent ainsi leur traitement à partir de la racine de l'arbre ou tous les objets sont regroupés en un seul cluster. À chaque itération, les clusters les plus hétérogènes sont divisés en deux jusqu'à ce que l'ensemble des objets fassent partie de leur propre cluster. Toutefois, sa complexité le rend inefficace sur de larges jeux de données [8]. De plus, la première injection de données ainsi que l'ordre de celles-ci à un fort impact sur le résultat final. En outre, il n'est pas possible de défaire ou modifier les étapes précédentes du traitement. Une fois une instance assignée à un cluster, il n'est plus possible de la déplacer pour effectuer d'éventuelles modifications ou corrections [10]. Dans notre cas la base de CV utilisée n'étant pas de taille importante le clustering hiérarchique reste une méthode applicable.
Cependant, la problématique à résoudre est la gestion des filières intégrant plusieurs domaines comme la filière MIASHS de Nanterre qui possède une dimension mathé-

matique et une informatique. Les données étant représentées sous forme d'arbre cela entrainerait une répétition au niveau des résultats.

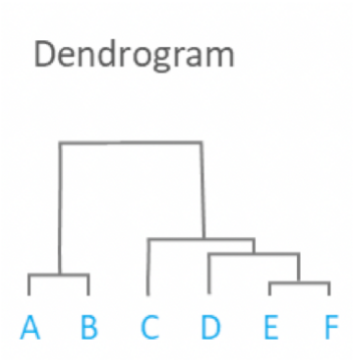

FIGURE 1.7 – Exemple de dendrogramme

1.4.2 Le clustering par partitionnement

Le clustering par partitionnement contrairement au clustering hiérarchique qui utilise un arbre afin de représenter les différents groupes de données va classifier les différents objets en groupe en fonction de leurs similarités. Cependant, ce mode de fonctionnement pause un problème concernant le choix de la «bonne représentation» en fonction d'un critère choisi, le but devient alors de rechercher une représentation optimale de son critère à travers plusieurs itérations.[2] L'algorithme le plus utilisé par ce type de méthode est K-means qui sera présenté dans la suite de ce document. Dans le cas du clustering par partitionnement, il existe une sous-catégorie nommée le partitionnement flou. Celle-ci a recours à une autre version de l'algorithme k-means appelée *Fuzzy k-means* ou k-moyennes flou. Cet algorithme cherche à minimiser la fonction illustrée par la figure 1.4.

$$\sum_{j=1}^{k} \sum_{x_i \in C_j} u_{ij}^{m} (x_i - \mu_j)^2$$

FIGURE 1.8 – Fonction objectif de Fuzzy K-Means

Dans la figure ci-dessus (figure 1.5),

- u_{ij} est le degré selon lequel une observation x_i appartient à un cluster c_j.
- μ_j est le centre d'un cluster j.
- m est le «fuzzifier».

  Contrairement aux méthodes de clustering dites dures, lorsque l'on a recours au clustering flou, il est possible que des données fassent partie de plusieurs clusters. De plus, l'appartenance d'un objet à un cluster est ici décidée par la proximité entre le centre du cluster traité et l'objet en question. [7] Cet algorithme reste toutefois soumis aux mêmes restrictions que l'algorithme K-Means classique dans le fait qu'il requiert de spécifier le nombre de clusters souhaités.

1.4.3 Le clustering basé sur des mélanges de modèles

Cette approche est adoptée lors de l'utilisation d'apprentissage automatique et au traitement de données manquantes ou cachées. Par rapport à d'autres approches basées sur des métriques permettant de déterminer le nombre de classes nécessaires ou encore le degré d'incertitude [3]. Les limites de cette méthode résident principalement dans les limitations entrainées par le type de données utilisées et la nécessité de formuler des hypothèses sur la distribution des observations rarement vérifiables dans la réalité.[2]

1.4.4 Le clustering conceptuel

Le clustering conceptuel est un paradigme d'apprentissage non supervisé ayant fait son apparition durant les années 1980. Cette méthode se différencie du cluste-

ring de données classique par le fait qu'elle génère une description de concept pour chaque classe générée. Un autre facteur de différenciation est le fait que les phases de clusterisation et de caractérisation des données ne sont pas indépendantes.[11] Un exemple d'algorithme se basant sur cette méthode est COBWEB(figure 1.5) qui est un algorithme utilisant les concepts du clustering hiérarchique et produira par conséquent en sortie une hiérarchie de concept. La limite de cet algorithme est le fait que celui-ci traite difficilement les attributs numériques[2], de plus, bien qu'étant utilisé pour la découverte de classes d'objets dans d'importants volumes de données [13]. Le stockage de l'ensemble des instances d'une hiérarchie peut représenter une nouvelle problématique sur des volumes importants de données.

```
Function Cobweb (object, root)
  Incorporate object into the root cluster;
    If root is a leaf then
      return expanded leaf with the object;
    else choose the operator that results in the
    best clustering:
      a) Incorporate the object into the best host;
      b) Create a new class containing the object;
      c) Merge the two best hosts;
      d) Split the best host;
    If (a) or (c) or (d) then
      call Cobweb (observation, best host);
```

FIGURE 1.9 – Algorithme Cobweb

L'algorithme de Kruskal

Créé en 1956 par Joseph Kruskal, cet algorithme utilise comme entrée un graphe connexe non orienté et pondéré (figure 1.8) et va considérer chaque arête par ordre croissant. Si l'arête sélectionnée ne crée pas de cycle, celle-ci sera utilisée dans la construction d'un arbre couvrant de poids minimum.
Les algorithmes de Prim et Kruskal possédant chacun une part d'indéterminisme, il est tout à fait possible que chacun renvoie un arbre différent tout en utilisant le même graphe de départ. Les solutions données seront toutefois jugées optimales pour les deux algorithmes.

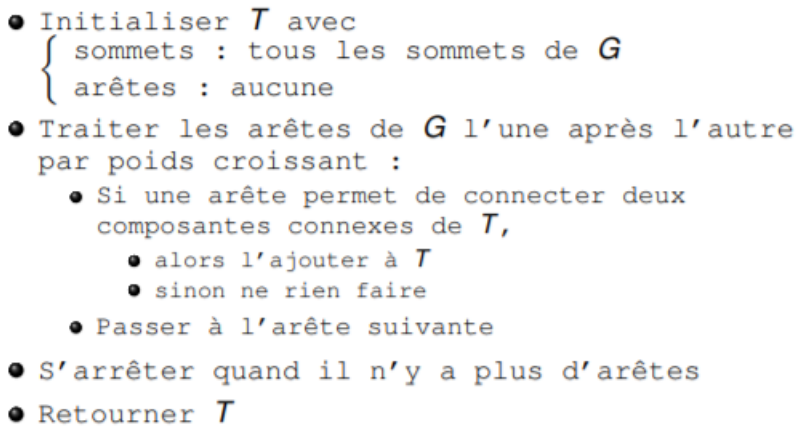

FIGURE 1.10 – Algorithme de Kruskal

1.4.5 K-means

L'algorithme K-means est l'algorithme le plus populaire, celui-ci peut être utilisé dans plusieurs domaines tels que :

— Utilisation du clustering dans un contexte de Data Mining.
— Clustering de documents qui dans notre cas seraient les CV d'anciens étudiants.
— La segmentation d'un jeu de données en fonction de critères.

Celui-ci recherche la meilleure division possible au sein d'un jeu de données [10] et possède comme avantage une certaine facilité d'implémentation. Cependant, il impose de connaitre le nombre de clusters **K** souhaités et par conséquent une bonne connaissance des données utilisées. L'une des solutions possibles lorsqu'un grand jeu de données est utilisé afin de déterminer le nombre de clusters voulus est de lancer l'algorithme avec différentes valeurs et de calculer ensuite la variance entre les résultats obtenus. Celle-ci représente ainsi la somme des distances entre chaque *centroïde*.

K-means fonctionne de la façon suivante :

— Choix d'un nombre de clusters K
— Affectation de chaque point au groupe dont il est le plus proche.
— Itération jusqu'à ce qu'il n'y ait plus de changements au niveau des centroïdes, c'est-à-dire que ceux-ci ne bougent plus lors des itérations.

Dans notre cas qui est la clusterisation de documents en fonction des types de parcours. Ceux-ci représentant différents tags en fonction du document étudié,nous sommes par conséquent dans un problème classique de classification pour lequel K-Means représente une solution possible. Dans cette situation, un premier traitement de chaque document est requis afin de pouvoir les représenter sous forme de vecteurs. Il est ensuite possible d'utiliser la fréquence d'apparition de certains termes afin d'identifier les mots les plus fréquents et ainsi aider à la classification du document étudié. Les vecteurs de documents sont ensuite clusterisés afin d'identifier les similarités dans un groupe de documents. À noter qu'il existe d'autres applications possibles à K-means telles que :

— Segmentisation de clientèle
— Analyse d'appels enregistrés
— Prédiction de crime [5]

1.4.6 Agglomerative Hierarchical Clustering

Les techniques de clustering agglomératives partent d'un ensemble de points formant un cluster. Ensuite, les deux clusters les plus proches sont fusionnés successivement jusqu'à ce qu'il n'y est plus qu'un unique cluster. [12] Les techniques de clustering agglomératives peuvent fonctionner de deux façons, ascendante ou descendante. Ce type d'approche figure parmi les plus utilisés lorsqu'il existe un besoin de regrouper des objets au sein de clusters basés sur leur similarité. L'agglomerative clustering est également connu sous le nom d'AGNES (Agglomerative Nesting) tandis que l'agglomerative hierarchical clustering peut être également appelé HAC. Lorsque la méthode bottom-up est utilisée, cet algorithme fonctionne la façon suivante :

— Chaque objet est traité en tant que cluster sous la forme d'un singleton.
— Les paires de clusters sont successivement fusionnées jusqu'à ce que tous les clusters fassent partie d'un unique cluster contenant tous les objets.

Le résultat de ce traitement est un dendrogramme (figure 1.3) représentant les objets.[3] En utilisant la méthode descendante, une méthode séparant les clusters est nécessaire. L'algorithme dans ce cas de figure sépare les clusters de façon récursive jusqu'à ce que tous les objets fassent partie de leur propre cluster. À noter qu'également dans cette méthode, les clusters sont considérés comme des singletons. L'avantage de l'approche ascendante est que celle-ci peut se révéler plus rapide si l'on se trouve dans un cas où il n'est pas nécessaire de générer une hiérarchie dans son intégralité.[6] L'inconvénient de ces procédés est qu'ils possèdent une complexité O_n^3 tout en nécessitant O_n^2 de mémoire ce qui le rend trop lent même sur des jeux de données de taille moyenne. Il existe toutefois des méthodes agglomératives possédant la même complexité, utilisées dans des cas particuliers que sont le single linkage et complete linkage clustering. À l'exception de ces deux autres méthodes, il n'est pas garanti qu'une solution optimale soit trouvée en ayant recours à ces algorithmes à moins de fournir une heuristique permettant d'atteindre une solution.

1.4.7 DBSCAN

DBSCAN est un algorithme basé sur le partitionnement de données. Cet algorithme utilise deux principaux paramètres qui sont la distance minimale entre deux points et le nombre de points minimum devant se trouver dans un rayon donné afin qu'ils soient considérés comme un cluster[9]. Le choix d'une bonne mesure de la distance reste critique comme dans toute autre méthode de clustering. En effet, si la valeur choisie est trop petite, une partie des données risque d'être considérée en tant qu'*outlier*. C'est-à-dire des observations peu fréquentes sortantes de la norme. L'algorithme DBSCAN sert dans des situations ou l'on cherche à déterminer des structures au sein d'un jeu de données. Celui-ci peut être exprimé en peudo-code.(figure 1.5). Dû à sa popularité, cet algorithme est souvent directement importé à travers des libraires Python ou R. Cet algorithme offre comme avantages le fait qu'il n'a

Algorithm 1 The DBSCAN algorithm. Input: A set of points X, distance threshold eps, and the minimum number of points required to form a cluster, $minpts$. Output: A set of clusters.

```
1:  procedure DBSCAN(X, eps, minpts)
2:      for each unvisited point x ∈ X do
3:          mark x as visited
4:          N ← GETNEIGHBORS(x, eps)
5:          if |N| < minpts then
6:              mark x as noise
7:          else
8:              C ← {x}
9:              for each point x' ∈ N do
10:                 N ← N \ x'
11:                 if x' is not visited then
12:                     mark x' as visited
13:                     N' ← GETNEIGHBORS(x', eps)
14:                     if |N'| ≥ minpts then
15:                         N ← N ∪ N'
16:                 if x' is not yet member of any cluster then
17:                     C ← C ∪ {x'}
```

FIGURE 1.11 – Algorithme DBSCAN

pas besoin de plus de paramètres que la distance, ici marquée *eps* et le nombre de moins minimum afin de constituer un cluster représenter ici par *minpts*. De plus, celui-ci n'est pas très sensible à l'ordre des données pour son traitement. Cependant, la qualité du résultat est grandement liée au choix d'une bonne mesure de distance. En outre, un degré de compréhension de l'échelle appliquée et des données étudiées est nécessaire afin de pouvoir choisir une mesure de distance pertinente.
Une étude a montré qu'il est possible de combiner son propre algorithme avec DBSCAN et d'utiliser celui-ci pour tout ce qui concerne la détection du bruit dans un jeu de données. Cet algorithme étant capable de détecter dans un rayon donné tous les points de donnée. Dans un cas où plusieurs exécutions de DBSCAN montrent qu'un point est isolé, c'est-à-dire que celui-ci est dans une zone à faible densité. Ce point peut être réellement considéré comme du bruit et il est possible de le supprimer afin de perfectionner le jeu de données étudié.[4]

1.5 Analyse et conclusion

Nous avons relevé dans un premier temps dans la figure ci-dessous les principaux avantages et inconvénients de chacune des méthodes étudiées précédemment.

Méthode de clustering	Avantages	Inconvénients
Hiérarchique	Ne nécessite pas d'informations sur le nombre de clusters requis Facilité d'implémentation	Qualité du résultat dépendant de la méthode utilisée (Bottom-up ou Top-down) Scalabilité Lisibilité des résultats sur d'important jeu de données
Par partitionnement	Facilité d'implémentation Scalable	Modifications non possibles après la fin du traitement. Pauvre interprétabilité des résultats
Conceptuel	Capable de détecter les variables représentant du bruit Fonctionne sur une grande variété de données.	Traitement difficile de données numériques. Le stockage des résultats sur d'important jeu de données
Mélange de modèles	Reste fonctionnel même avec la présence de données cachées ou manquantes	Sensible à la qualité des hypothèses formulées Dépendant du type de données utilisées.

FIGURE 1.12 – Comparatif des méthodes de clustering

Avec ce premier tableau, nous pouvons éliminer des méthodes potentiellement utilisables, la méthode conceptuelle. Celle-ci traitant difficilement les données numériques, n'est par conséquent pas adaptée à notre cas. La méthode par mélange de modèles est également non utilisable, la qualité des résultats étant très fortement liée aux hypothèses formulées par un utilisateur en début de traitement. Afin de pouvoir choisir entre les deux méthodes restantes, la plus adaptée à notre cas, nous nous baserons sur les mêmes critères que ceux énoncés dans l'introduction . C'est-à-dire :

— Capacité de la méthode à traiter un jeu de données numérique
— La difficulté d'implémentation
— La sensibilité au bruit
— La scalabilité de la méthode

La figure ci-dessous présente la méthode hiérarchique et par partitionnement au vu de ces critères.

Méthode de clustering	Difficulté d'implémentation	Scalabilité	Sensibilité au bruit	Capacité à traiter des données numériques
Hiérarchique	Facilité d'implémentation	Dépendante de l'approche choisie (Top-Down ou Bottom-up)	Sensibilité dépendante de la méthode de linkage choisie	Fonctionne sur des données numériques
Par partitionnement	Facilité d'implémentation	K-means applicable sur de large jeu de données	Tous les objets sont assignés à des clusters	Ne fonctionne uniquement que sur des données numériques

FIGURE 1.13 – Évaluation des méthodes de clustering hiérarchique et par partitionnement

Comme on peut l'observer dans ce tableau, les deux méthodes possèdent toutes deux une implémentation simple. Toutefois, l'approche hiérarchique est fortement dépendante de la méthode utilisée. Tandis que la méthode par partitionnement est applicable sur de larges jeux de données sans être sensible à une méthodologie extérieure particulière en plus de posséder la même facilité d'implémentation. Par conséquent, la méthode choisie pour notre implémentation sera l'approche par partitionnement.

Chapitre 2

Implémentation

2.1 Objectifs

Notre but étant de pouvoir proposer aux étudiants de première année les éventuelles voix qu'ils sont susceptibles de poursuivre tout au long de leurs études. Notre solution doit pouvoir répondre aux questions suivantes :

— Donner une filière de départ, quel est le parcours suivi ?

— Pouvoir fournir une représentation de ce parcours

Dans cette optique, le premier objectif de cette étude est dans un premier temps de pouvoir regrouper les différents CV en fonction des différentes filières. Cette première phase de classification nous permettra par la suite de conditionner l'algorithme utilisé. Une fois ce premier traitement effectué, il sera ensuite nécessaire de récupérer toutes les filières parcourues par l'individu. Enfin, une fois cette étape de catégorisation du CV et la récupération du chemin parcouru réalisée. L'objectif final est de pouvoir représenter le résultat sous forme graphique interprétable par les étudiants.

2.2 Préparation et caractérisation des données

2.2.1 Le jeu de données

Pour cette étude, le jeu de données utilisé contiendra environ 2000 CV d'un projet pouvant être trouvé à l'adresse suivante :

— `https://github.com/JAIJANYANI/Automated-Resume-Screening-System`

Celui-ci contient différents CV au format PDF,DOC et docx. La majorité de ces documents sont construits de la façon suivante :

— Expérience professionnelle

— Éducation

— Loisirs et autre

À noter, bien que cette structure soit la plus récurrente, l'ordre des différentes sections peut tout de même changer en fonction des documents.

Un premier tri a été effectué afin de filtrer les documents en fonction de leur format afin de ne retenir que ceux au format **.doc** ou **.docx** afin de faciliter les traitements visant ensuite à les classifier. En outre, ce premier tri permettra par la suite de minimiser la charge de calcul afin que les étapes de traitement et d'analyse ne soient pas

impactées par un temps de traitement trop important. À noter que bien que cette première étape de tri puisse être réalisée de façon manuelle. L'objectif final étant de proposer cette solution sous la forme d'un programme, il est plus intéressant que cette phase de tri puisse s'effectuer de façon automatique une fois le jeu de données fourni.

2.2.2 Choix de l'algorithme

Afin de pouvoir choisir l'algorithme le plus adapté à notre cas, celui-ci doit pouvoir répondre aux critères suivant :

— Capacité à traiter des documents
— Capacité à gérer une montée en charge
— Consommation de mémoire

Comme vu précédemment, l'algorithme K-means, bien que celui-ci puisse traiter des documents texte, il impose toutefois de connaitre le nombre de clusters souhaités afin de pouvoir effectuer son traitement.
Dans notre cas, cette contrainte ne représente pas de difficultés les CV étant regroupés en fonction des secteurs d'activités (figure à voir). En outre, l'algorithme choisi étant utilisé à travers la librairie python « scikit-learn », celle-ci propose un tableau comparatif (figure 2.1) des différents algorithmes qu'il est possible d'implémenter en plus de DBSCAN et Agglomerative clustering. Au vu des différents cas

Method name	Parameters	Scalability	Usecase	Geometry (metric used)
K-Means	number of clusters	Very large `n_samples`, medium `n_clusters` with MiniBatch code	General-purpose, even cluster size, flat geometry, not too many clusters	Distances between points
Affinity propagation	damping, sample preference	Not scalable with n_samples	Many clusters, uneven cluster size, non-flat geometry	Graph distance (e.g. nearest-neighbor graph)
Mean-shift	bandwidth	Not scalable with `n_samples`	Many clusters, uneven cluster size, non-flat geometry	Distances between points
Spectral clustering	number of clusters	Medium `n_samples`, small `n_clusters`	Few clusters, even cluster size, non-flat geometry	Graph distance (e.g. nearest-neighbor graph)
Ward hierarchical clustering	number of clusters or distance threshold	Large `n samples` and `n_clusters`	Many clusters, possibly connectivity constraints	Distances between points
Agglomerative clustering	number of clusters or distance threshold, linkage type, distance	Large `n samples` and `n_clusters`	Many clusters, possibly connectivity constraints, non Euclidean distances	Any pairwise distance
DBSCAN	neighborhood size	Very large `n_samples`, medium `n_clusters`	Non-flat geometry, uneven cluster sizes	Distances between nearest points
OPTICS	minimum cluster membership	Very large `n_samples`, large `n_clusters`	Non-flat geometry, uneven cluster sizes, variable cluster density	Distances between points
Gaussian mixtures	many	Not scalable	Flat geometry, good for density estimation	Mahalanobis distances to centers
Birch	branching factor, threshold, optional global clusterer.	Large `n_clusters` and `n_samples`	Large dataset, outlier removal, data reduction.	Euclidean distance between points

FIGURE 2.1 – Comparatif des algorithmes de clustering

d'utilisation proposés par ce tableau, les trois algorithmes étudiés dans ce document peuvent être implémentés. K-means étant le plus courant et possédant une facilité d'implémentation sera l'algorithme utilisé étant donné qu'il est également possible de l'utiliser dans le traitement de documents. La représentation des données choisie n'est pas adaptée à l'utilisation de DBSCAN. De plus, nous sommes dans un cas d'apprentissage non supervisé, cet algorithme nécessite une configuration établie en amont par un utilisateur. En revanche,K-means bien qu'ayant besoin du nombre de clusters souhaités peut fonctionner sans que des labels lui soit fourni. La méthode utilisée sera donc un clustering par partitionnement en ayant recours à l'algorithme K-means.

2.3 Caractérisation et classification des parcours

2.3.1 Démarche

Afin de pouvoir utiliser l'algorithme K-Means, il est nécessaire dans un premier temps de transformer notre base de données en un format interprétable par nos algorithmes. Afin de pouvoir fonctionner, K-means utilise des données numériques sous la forme illustrée la figure 2.2. Par conséquent, grâce à la structure des dossiers ou sont stockés, il est possible de créer une énumération afin de pouvoir attribuer une valeur aux différentes catégories. Cette structure nous permet de déterminer le K maximum qu'il est possible d'adopter pour les différentes opérations de l'algorithme. Une fois cette énumération créée, celle-ci nous permet donc de catégoriser les différents CV en fonction des différents secteurs intégrés par un individu. Cette première étape apporte un premier élément de réponse quant à la modélisation des trajectoires. En effet, les différentes clés étant stockées dans l'ordre ou celles-ci sont rencontrées ceci nous permet dans un premier temps d'obtenir le chemin suivi.

	File Name	Secteur Key_	Secteur Key_	Secteur Key_	Secteur Key_	Secteur Key_	Secteur Key_	Secteur Key_	Secteur Key_	Secteur Key_8
2	ASK_Carlyn M	2	4	12	14	0	0	0	0	0
3	Cyrus Global	2	3	4	8	10	11	12	14	15
4	Partners_Bet	2	4	8	12	0	0	0	0	0
5	WorldQuant_	2	11	12	14	0	0	0	0	0

FIGURE 2.2 – Extrait du jeu de données

Comme illustrée dans la figure ci-dessus, chaque mot clé correspondant à un secteur d'activité est renseigné dans l'ordre ou ceux-ci sont rencontré. Ceci permet d'obtenir un premier aperçu des filières parcourues par un individu. Afin de pouvoir prendre en compte les éventuelles répétitions des mots clés recherchés durant les traitements, lorsque l'un de ceux-ci est rencontré, celui-ci est stocké dans un dictionnaire avec la clé associée. Ceci permet d'éviter la répétition de clé dans le fichier csv produit à la fin du traitement. À noter que la valeur 0 sert à représenter un vide afin que le jeu de données puisse être interprété par K-means.
Une fois cette première étape exécutée, il est alors possible d'utiliser K-means pour la création de nos clusters. Dans notre cas, nous avons tenté de lancer l'algorithme sans lui fournir de labels au préalable afin de pouvoir mesurer son taux de précision.(figure 2.3)

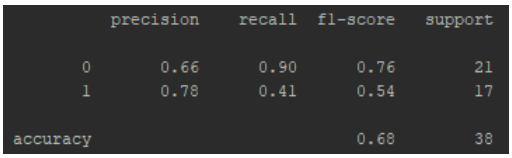

	precision	recall	f1-score	support
0	0.66	0.90	0.76	21
1	0.78	0.41	0.54	17
accuracy			0.68	38

FIGURE 2.3 – Résultat de création de clusters par K-means

Dans la figure ci-dessus :

- Précision fait référence au score obtenu par la précision de classification utilisée.
- Recall correspond à la proportion de documents pertinents récupérés.
- F1-score mesure la précision du test.

Dans cet exemple, nous avons créé un cluster contenant tous les CV dont le propriétaire a commencé par une filière administrative. On peut observer un taux de 68% de réussite dans la détermination de l'appartenance à la filière recherchée sans aucun apport de la part de l'utilisateur. Cependant, ce premier essai a été effectué sur une fraction du jeu de données et globale. Cette première tentative permet dans un premier temps d'évaluer le comportement et la précision de K-means pour nos documents. À noter que la mesure de distance utilisée est la distance euclidienne utilisée par défaut par l'algorithme K-mean.

Environnement

Ci-dessous les caractéristiques de la machine utilisée durant cette étude ainsi que les différents logiciels et librairies.

- Mémoire Ram : 16 Go
- Espace disque : 500 Go
- Logiciel utilisé : Pycharm
- Langage : Python
- Librairies utilisées : sklearn,numpy,pandas et seaborn

2.3.2 Problématiques restantes

Nous avons pu voir qu'il existe une multitude de méthodes applicables afin d'ordonner nos données, cependant la première problématique rencontrée pour cette implémentation a été le traitement des CV. Il est en effet possible de récupérer aisément les mots clés recherchés tels que « Sales » ou encore « Law » comme filière universitaire ou secteur d'activité professionnelle. La difficulté vient toutefois du fait qu'il est nécessaire de différencier dans quelle rubrique du CV, dans notre cas « Education » ou « Work experience » ces mots apparaissent. Ce type de découpage de document est en général utilisé par les services de recrutement d'entreprise lorsqu'un recruteur cherche un profil en fonction de mots clés ce qui fait que ces solutions sont propriétaires. Un projet open source disponible à l'adresse suivante :

— `https://github.com/tramyardg/CVparser`

Ce projet aurait pu représenter une solution possible. Celui-ci renvoie une chaine de caractère au format JSON contenant les différentes rubriques découpées. Malencontreusement, ce projet n'est plus fonctionnel ni maintenu par son créateur. La seconde problématique restante vient du fait que pour notre cas d'étude, une fois les différents parcours universitaires ainsi que le secteur occupé ont été classifiés, afin de pouvoir modéliser ces trajectoires sous forme graphique. Il serait nécessaire de pouvoir récupérer le contenu d'un objet lui-même contenu dans un cluster donné et pouvoir considérer chaque ligne comme une unique occurrence afin de pouvoir modéliser celle-ci sous forme de point. Cette seconde problématique est par conséquent fortement liée à la première. En effet, le fait qu'il soit nécessaire dans un premier temps de pouvoir traiter les différentes rubriques d'un document une à une et d'être en mesure de ne récupérer que des données pertinentes.

2.4 Conclusion

Dans ce mémoire, nous avons présenté les différentes méthodes de clustering, dont le clustering par partitionnement qui semble correspondre à notre cas. Toutefois, le clustering hiérarchique reste prometteur. Cependant le traitement des objets regroupés et le découpage de document ont entrainé la rencontre de nouvelle problématique durant cette étude.
L'analyse de données étant un élément essentiel de domaine qui de nos jours possède une forte popularité tel que le Big data. Les méthodes de clustering utilisées dans ce domaine représentent une opportunité prometteuse pour notre problématique. En effet, celles-ci nous permettent dans un premier temps d'ordonner nos données afin de pouvoir en dégager les populations principales. Cette première étape de classification et représentation des données permet ensuite de faciliter les différents traitements.
Dans la dernière partie, nous avons présenté les premières étapes d'une méthode visant à tirer profit de la classification obtenue à travers des processus de clustering. Plus particulièrement, nous avons eu recours à un clustering par partitionnement afin de pouvoir identifier les différentes populations. Cependant, cette méthode pose de nouvelles problématiques dans le cas de parcours contenant plusieurs filières et n'est par conséquent pas la plus idéale. De plus, il reste encore une partie conséquente de l'implémentation regardant l'extraction de texte à réaliser.

Bibliographie

[1] P. Arabie, L. J. Hubert, and G. D. Soete. Clustering validation : Results and implications for applied analyses. clustering and classification. 1996.

[2] G. Cleuziou. Une méthode de classification non-supervisée pour l'apprentissage de règles et la recherche d'information. *Université d'Orléans*, 2004.

[3] V. Georgescu, N. Desassis, S. Soubeyrand, A. Kretzschmar, and R. Senoussi. Classification basée sur des mélanges de modèles hiérarchiques bivariés. *42èmes Journées de Statistique*, 2010.

[4] D. Godfrey, C. Johns, C. Sadek, C. Meyer, and S. Race. A case study in text mining : Interpreting twitter data from world cup tweets. 21 august 2014.

[5] V. Jain, Y. Sharma, A. Bhatia, and V. Arora. Crime prediction using k-means algorithm. *GRD Journals- Global Research and Development Journal for Engineering | Volume 2 | Issue 5*, 2017.

[6] C. D. Manning, P. Raghavan, and H. Schütze. Introduction to information retrieval. *Cambridge University Press*, 2008.

[7] R.Suganya and R.Shanthi. Fuzzy c- means algorithm- a review. *International Journal of Scientific and Research Publications, Volume 2, Issue 11*, 2012.

[8] M. Santini. Advantages and disadvantages of k-means and hierarchical clustering (unsupervised learning). *Machine Learning for Language Technology*, 2016.

[9] E. Schubert, J. Sander, M. Ester, H.-P. Kriegel, and X. Xu. Dbscan revisited, revisited : Why and how you should (still) use dbscan. *ACM Trans. Database Syst. 42, 3, Article 19*, 2017.

[10] D. Sonagara1 and S. Badheka2. Comparison of basic clustering algorithms. *International Journal of Computer Science and Mobile Computing*, 2014.

[11] R. E. Stcpp. Concepts in conceptual clustering. *University of Illinois at Urbana-Champaign*.

[12] P.-N. Tan, M. Steinbach, A. Karpatne, and V. Kumar. *Cluster Analysis : Basic Concepts and Algorithms*. Pearson ; 2 edition (January 4, 2018), 2018.

[13] M. Theodorakis, A. Vlachos, and T. Z. Kalamboukis. Using hierarchical clustering to enhance classification accuracy.